

Relatório Trabalho Prático 1

Integração de Sistemas de Informação

Aluno:

Thiago Yabuki de Araujo - a24207

Docente:

Luís Ferreira

Licenciatura em Engenharia de Sistemas Informáticos 3º ano

FIGURA 1 - DESCRIÇÃO PARA A IA DO MOCKAROO	6
Figura 2 - Geração dos dados utilizando a IA do Mockaroo	6
Figura 3 - Transformação de ficheiro CSV para XML com inserts para a base de dados	8
Figura 4 - Script SQL	9
Figura 5 - Captura de tela do ficheiro XML antes da alteração	9
Figura 6 - Alteração dos dados para "Integer"	10
Figura 7 - Captura de tela do ficheiro XML após a alteração	10
Figura 8 - Detalhes da separação do campo full_name para first_name e last_name	10
Figura 9 - Detalhes da formatação das letras maiúsculas	11
Figura 10 - Detalhes da importação do ficheiro CSV	11
Figura 11 - Detalhes da criação do ficheiro XML	12
Figura 12 - Transformação de um ficheiro XML para dois ficheiros XLS, um com filtragem e outro sem	
ALTERAÇÕES	13
Figura 13 - Detalhes da leitura do ficheiro XML	13
Figura 14 - Detalhes do Select Values	14
Figura 15 - Detalhes da If field value is null	15
Figura 16 – Remoção do hífen no campo postal_code	15
Figura 17 - Remoção dos caracteres CEDEX e próximos digitos no campo postal_code	15
Figura 18 - Remoção de espaços no campo postal_code	16
Figura 19 - Detalhes da Filter Rows	16
Figura 20 - Detalhes do ficheiro XLS com a quantidade maior que 25	17
Figura 21 - Detalhes da criação do ficheiro XLS com a quantidade menor que 25	18
Figura 22 - Entrada do ficheiro Excel, remoção de campos e filtragem de estado do pedido	19
Figura 23 - Detalhe da importação do ficheiro XLS	20
Figura 24 - Remoção dos campos	20
Figura 25 - Filtragem do campo de status do pedido "Delivered"	21
Figura 26 - Criação do ficheiro Excel com os envios completos	21
FIGURA 27 - FILTRAGEM PARA O CAMPO DE STATUS DO PEDIDO "SHIPPED"	22
Figura 28 - Criação do ficheiro Excel com os envios despachados	23
Figura 29 - Criação do ficheiro Excel com os envios pendentes	24
Figura 30 – Visão geral do Job	26
FIGURA 31 - CAPTURA DE TELA DO EMAIL RECEBIDO	26
Figura 32 - QR Code	27

Índice

1.	Intro	odução	5
2.	Gera	ção de dados aleatórios	6
3.	Man	ipulações no Kettle	7
4.	Tran	sformações	8
	4.1.	Transformação 1 - CSV to XML	8
	4.2.	Transformação 2 - XML to XLS	. 13
	4.3.	Transformação 3 – XLS Edit	. 19
5.	Job .		. 25
6.	Víde	o de funcionamento do programa	. 27
7.	Conc	clusão	. 28

1. Introdução

O primeiro trabalho da Unidade Curricular de Integração de Sistemas de Informação tem como objetivo consolidar o conhecimento teórico e prático sobre as ferramentas de transformação de dados, que foram abordadas durante as aulas. Este trabalho propõe a utilização de ferramentas de ETL (Extract, Transformation and Load) para a manipulação e integração de dados.

Para o desenvolvimento deste trabalho, foi utilizado a plataforma Pentaho Data Integration, também conhecida como Kettle ou Spoon. O Pentaho oferece um conjunto diversificado de recursos para manipulação de dados, como a integração com diversos tipos de bancos de dados, criação e manipulação de tabelas, manipulação de ficheiros, além de funcionalidades para enviar e-mails e executar pings em sistemas remotos.

2. Geração de dados aleatórios

Para criação de dados aleatórios foi utilizado o <u>Mockaroo</u>. Este website permite a geração de dados aleatórios levando em consideração o tipo de dados de cada campo. Também permite gerar os campos através de inteligência artificial, que foi a utilização abordada neste trabalho, basta informar o problema, especificar a quantidade de campos que contém e ele retorna os campos preenchidos com os dados.

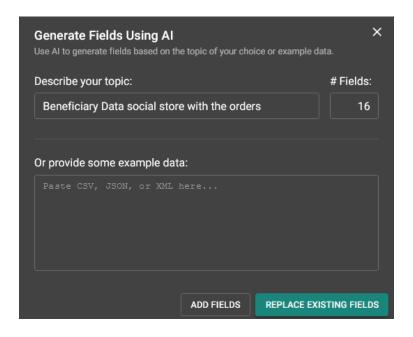


Figura 1 - Descrição para a IA do Mockaroo

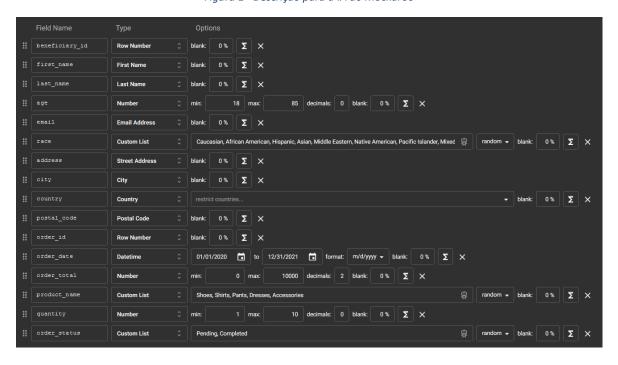


Figura 2 - Geração dos dados utilizando a IA do Mockaroo

3. Manipulações no Kettle

No Kettle temos dois tipos de ficheiros, o .ktr que pertence a uma Transformação e o .kjb que pertence a um Job. Como citado em aula, o Job é como se fosse um ficheiro "main.c" e a Transformação a uma função de um programa. O Job é responsável por chamar as Transformações que precisemos de usar. Foram realizadas três transformações nesse trabalho prático, falaremos sobre cada uma delas.

4. Transformações

4.1. Transformação 1 - CSV to XML

Esta transformação inicial faz uma leitura do ficheiro CSV com os dados gerados por IA, realiza um script em SQL para criar as tabelas, caso não exista na base de dados, a seguir divide o campo *full_name* do beneficiário em dois campos: *first_name* e *last_name*, formatando ambos em letras maiúsculas. Em seguida, o ficheiro XML é convertido em um ficheiro CSV. Por fim, é realizado um **INSERT** caso as tabelas estejam vazias, ou um **UPDATE** se já houver dados na base de dados.

Durante o processo, encontrei dificuldades com campos do tipo "Number" devido ao XML adicionar zeros extras para preencher o tamanho especificado pelo atributo "Length". Isso afetou as etapas seguintes. Para resolver essa questão, mudamos o tipo dos dados para "Integer", eliminando a necessidade de zeros adicionais e facilitando o processamento.

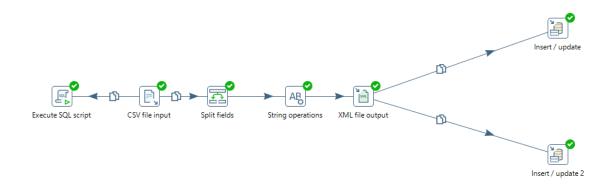


Figura 3 - Transformação de ficheiro CSV para XML com inserts para a base de dados

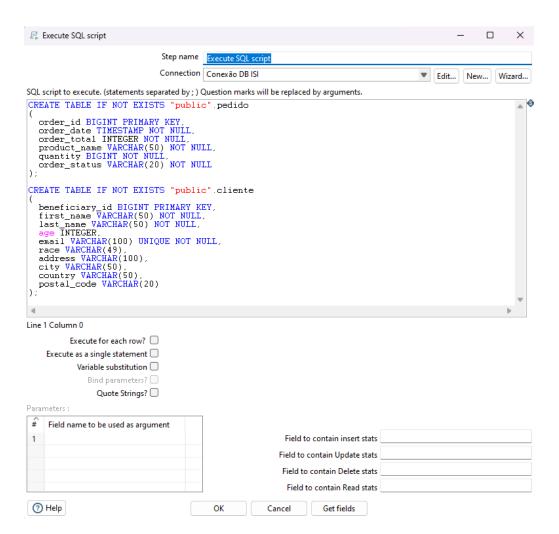


Figura 4 - Script SQL

```
▼<Rows>
 ▼<Row>
     <beneficiary_id>00000000000001/beneficiary_id>
     <first name>Valentina</first name>
     <last_name>Lanyon</last_name>
     <age>000000000000060</age>
     <email>vlanyon0@networksolutions.com</email>
     <race>Chickasaw</race>
     <address>032 Hayes Crossing</address>
     <city>Tsimlyansk</city>
     <country>Russia</country>
    <postal_code>347320</postal_code>
<order_id>000000000000001</order_id>
     <order_date>2021/01/12</order_date>
     <order_total>529</order_total>
     oduct_name>Nut - Pecan, Halves
     <quantity>00000000000036</quantity>
     <order status>Pending</order status>
   </Row>
```

Figura 5 - Captura de tela do ficheiro XML antes da alteração

#	Name	Type	Format	Length	Precision	Currency	Decimal	Group	Trim type
1	beneficiary_id	Integer	#	15	0	USD		,	none
2	first_name	String		11		USD		,	none
3	last_name	String		11		USD			none
4	age	Integer	#	15	0	USD		,	none
5	email	String		31		USD			none
6	race	String		49		USD			none
7	address	String		26		USD			none
8	city	String		18		USD			none
9	country	String		14		USD		,	none
10	postal_code	String		13		USD			none
11	order_id	Integer	#	15	0	USD		,	none
12	order_date	Date	MM/dd/yyyy			USD			none
13	order_total	Integer	#	15	0	USD	0		none
14	product_name	String		32		USD			none
15	quantity	Integer	#	15	0	USD	0		none
16	order_status	String		9		USD			none

Figura 6 - Alteração dos dados para "Integer"

```
<Rows>
 ▼<Row>
    <beneficiary_id>1
    <first_name>Valentina</first_name>
    <last_name>Lanyon</last_name>
    <age>60</age>
    <email>vlanyon0@networksolutions.com</email>
    <race>Chickasaw</race>
    <address>032 Hayes Crossing</address>
    <city>Tsimlyansk</city>
    <country>Russia</country>
    <postal_code>347320</postal_code>
    <order_id>1</order_id>
    <order_date>2021/01/12</order_date>
    <order_total>529</order_total>
    oduct_name>Nut - Pecan, Halves
    <quantity>36</quantity>
    <order_status>Pending</order_status>
```

Figura 7 - Captura de tela do ficheiro XML após a alteração

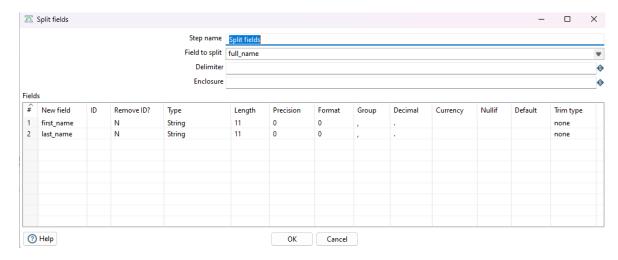


Figura 8 - Detalhes da separação do campo full_name para first_name e last_name

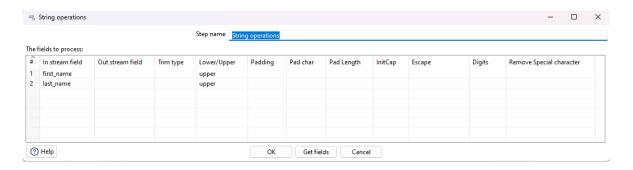


Figura 9 - Detalhes da formatação das letras maiúsculas

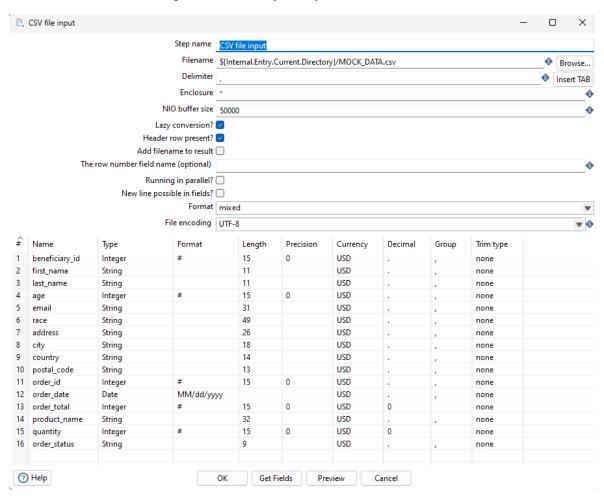


Figura 10 - Detalhes da importação do ficheiro CSV

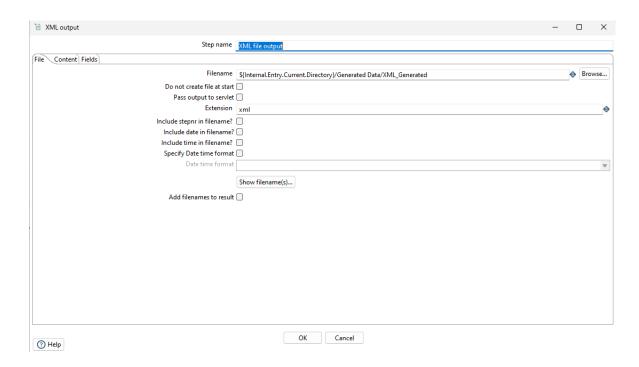


Figura 11 - Detalhes da criação do ficheiro XML

4.2. Transformação 2 - XML to XLS

Nesta segunda transformação, estamos a importar o ficheiro XML que foi criado na transformação anterior, o select values está "formatando" o formato da data do pedido obtido no ficheiro XML. Logo após temos a eliminação de valores nulos no campo de código postal, ou seja, todos os valores nulos vão ser substituídos por "N/A", após, temos três sequências de normalização utilizando expressões regulares, uma para remover espaços, outra para remover os hífens e outra para remover caracteres do campo postal_code. A seguir ocorre uma filtragem, caso a quantidade de pedidos feitas seja maior que 25, vão ser criados dois ficheiros Excel, um contendo os dados da quantidade de pedidos maior que 25 e outro armazenando os dados que são menor que 25.



Figura 12 - Transformação de um ficheiro XML para dois ficheiros XLS, um com filtragem e outro sem alterações

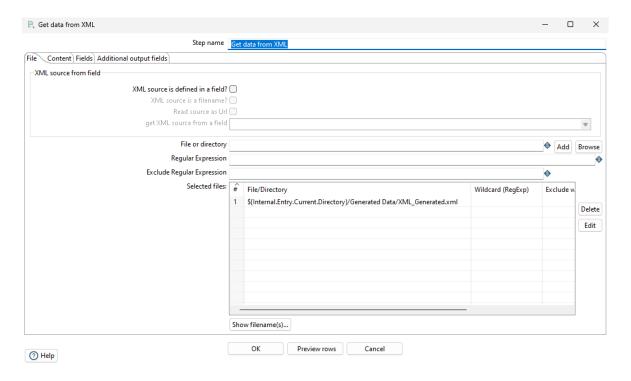


Figura 13 - Detalhes da leitura do ficheiro XML

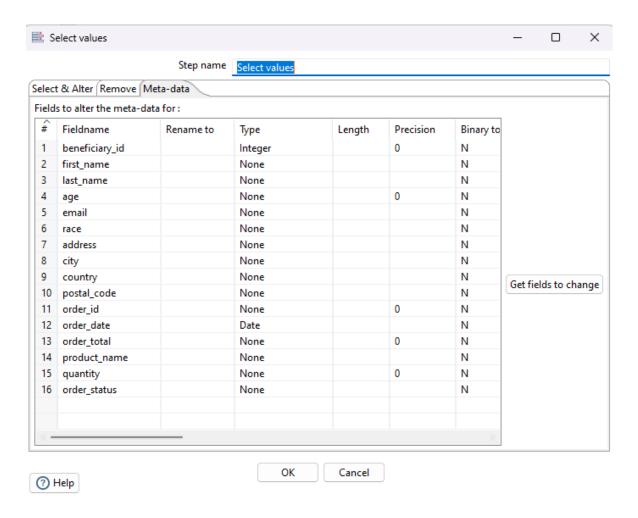


Figura 14 - Detalhes do Select Values

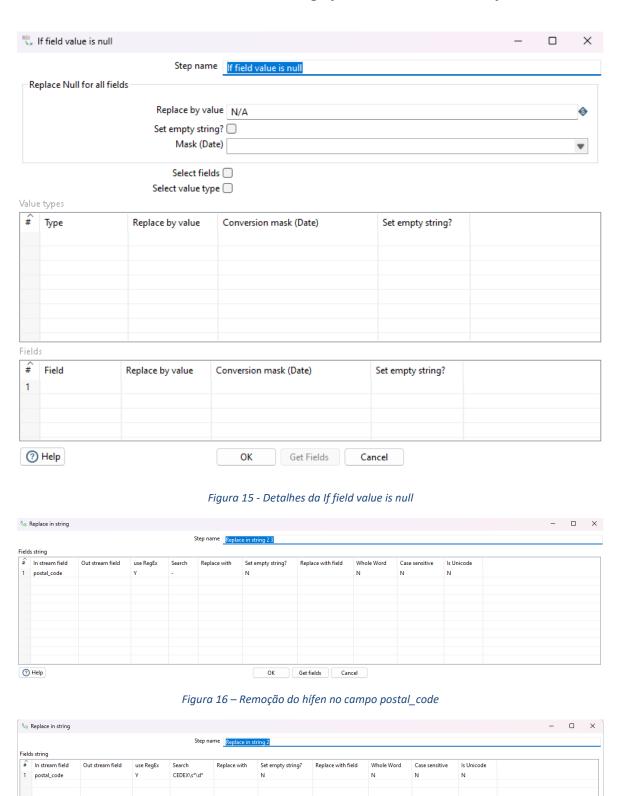


Figura 17 - Remoção dos caracteres CEDEX e próximos digitos no campo postal_code

Get fields

Cancel

OK

? Help

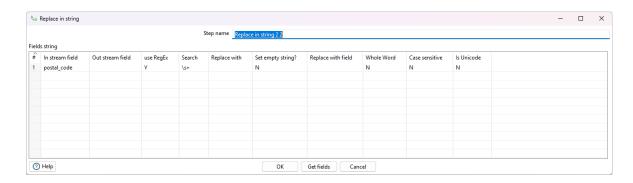


Figura 18 - Remoção de espaços no campo postal_code

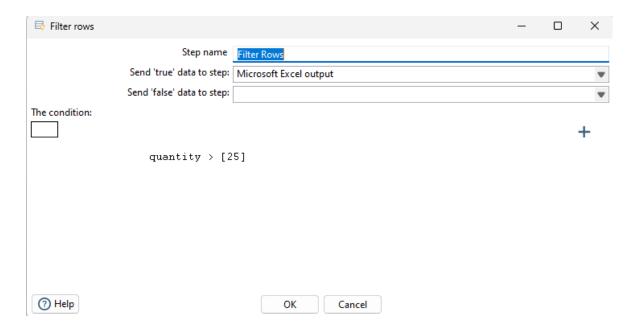


Figura 19 - Detalhes da Filter Rows

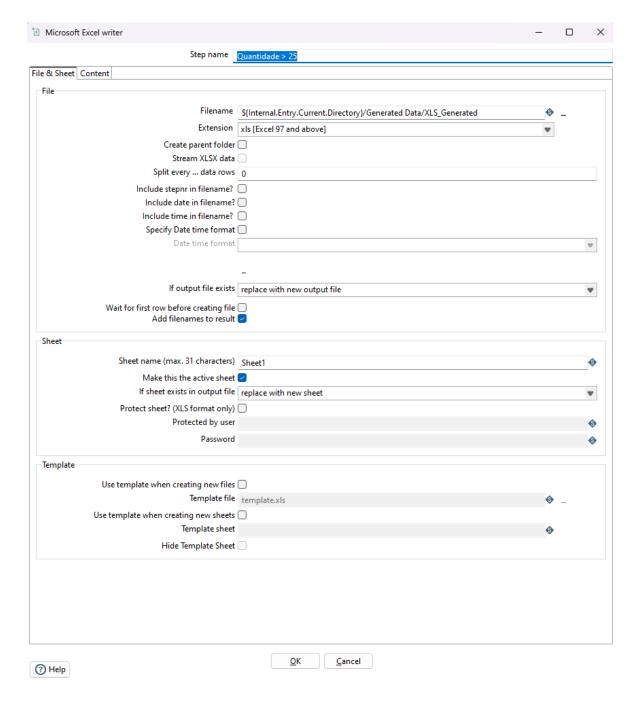


Figura 20 - Detalhes do ficheiro XLS com a quantidade maior que 25

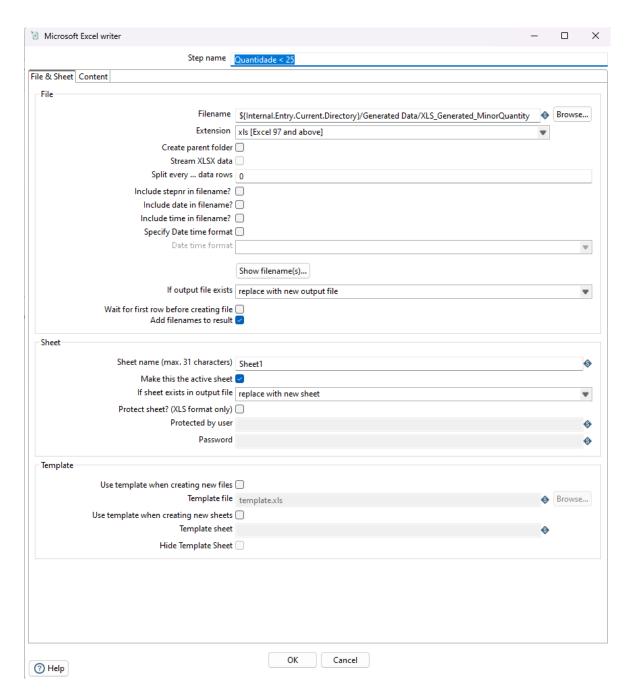


Figura 21 - Detalhes da criação do ficheiro XLS com a quantidade menor que 25

4.3. Transformação 3 – XLS Edit

Esta é a última transformação, onde campos irrelevantes para o usuário final do arquivo XLS são removidos, sendo eles os campos: age, email, race, address, city, country, e postal_code. Em seguida, o processo realiza uma filtragem com base no status do pedido. Se o status for Delivered, é criado um ficheiro Excel com os envios completos. Caso contrário, o fluxo segue para uma nova filtragem. Se o status for Shipped, são gerados dois ficheiro Excel: um para pedidos que cumprem a condição e outro para os que não cumprem.

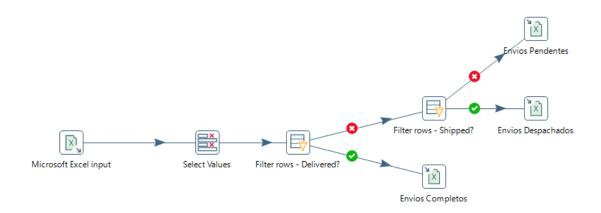


Figura 22 - Entrada do ficheiro Excel, remoção de campos e filtragem de estado do pedido.

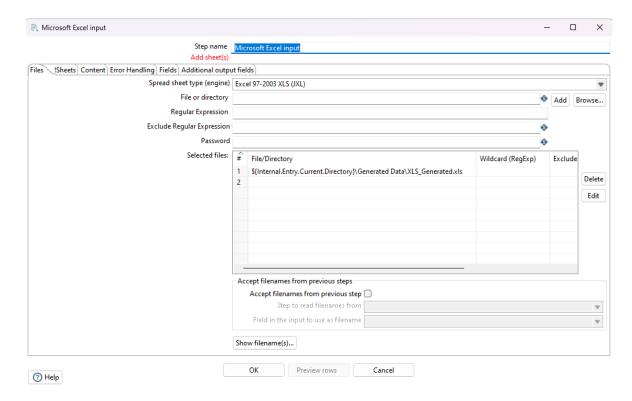


Figura 23 - Detalhe da importação do ficheiro XLS

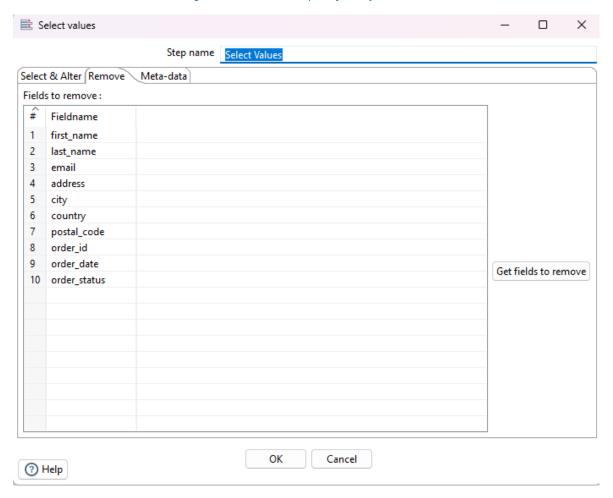


Figura 24 - Remoção dos campos

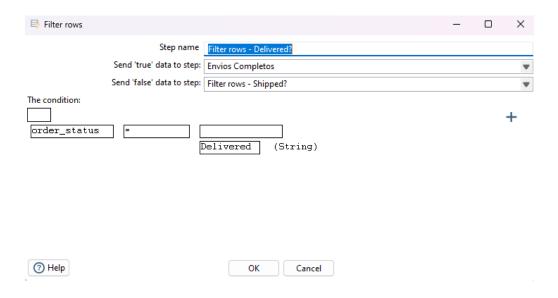


Figura 25 - Filtragem do campo de status do pedido "Delivered"

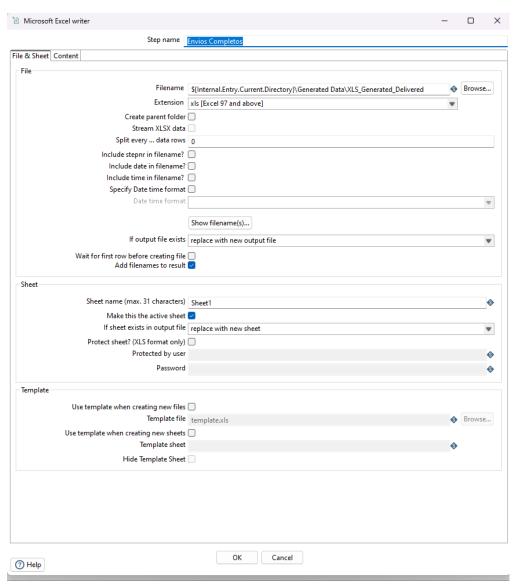


Figura 26 - Criação do ficheiro Excel com os envios completos

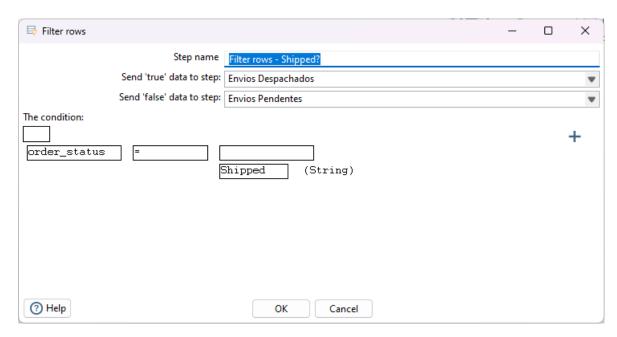


Figura 27 - Filtragem para o campo de status do pedido "Shipped"

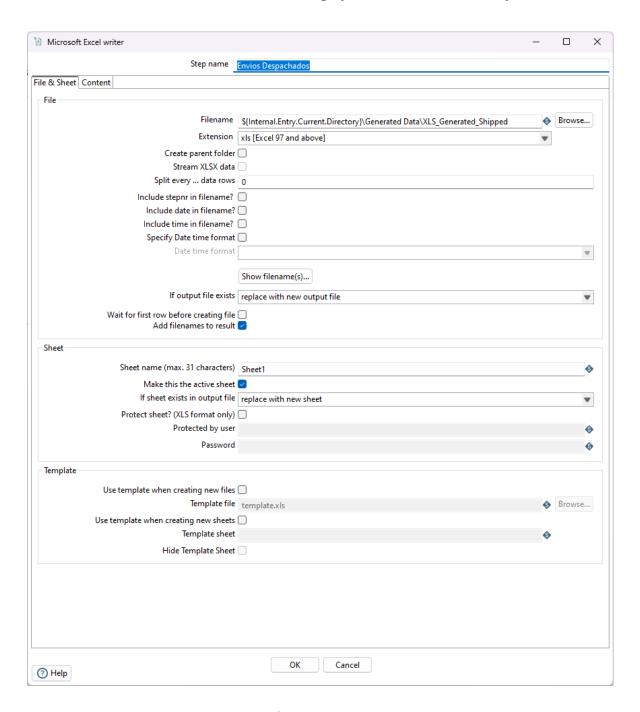


Figura 28 - Criação do ficheiro Excel com os envios despachados

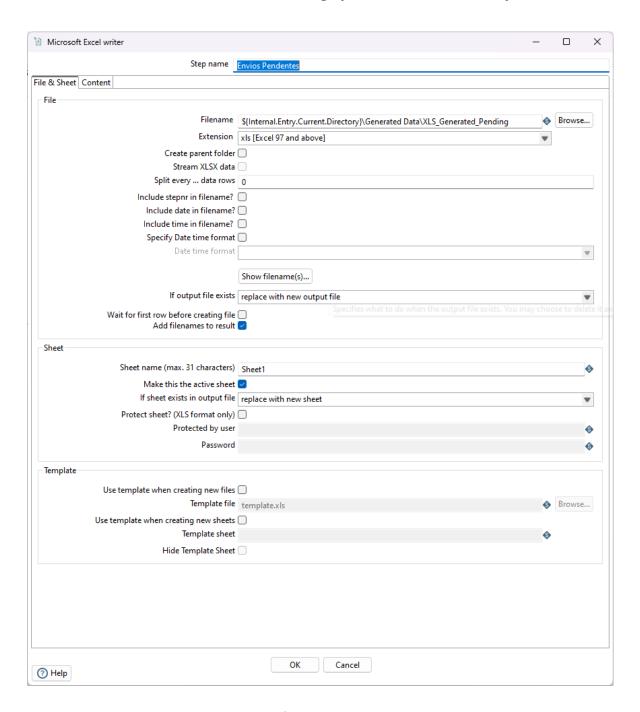


Figura 29 - Criação do ficheiro Excel com os envios pendentes

5. Job

Na criação do Job, iremos chamar todas as transformações que referenciamos anteriormente e também foram utilizadas algumas ferramentas que o Kettle nos fornece.

Para executar o Job, é necessário abrir com o Kettle o ficheiro START_JOB.kjb e clicar em Run.

O fluxo do Job é estruturado da seguinte forma:

- 1. Start
- 2. É criada uma pasta chamada "Generated Data" para armazenar os dados gerados
 - a. Caso não seja possível realizar a criação da pasta, o programa mostrará um erro e
 o Job será abortado.
- 3. É checada a conexão com a base de dados
 - a. Caso não seja possível conectar com a base de dados, o programa mostrará um erro e o Job será abortado.
- 4. Verificação da existência do ficheiro CSV.
 - a. Caso não seja encontrada a existência do ficheiro CSV, o programa mostrará uma mensagem de erro e o Job será abortado.
- 5. Faz uma chamada para a Transformação 1 CSV to XML.
- 6. Verificação da existência do ficheiro XML
 - a. Caso não seja encontrada a existência do ficheiro XML, o programa mostrará uma mensagem de erro e o Job será abortado.
- 7. Faz uma chamada para a Transformação 2 XML to XLS
- 8. Verificação da existência do ficheiro XLS
 - a. Caso não seja encontrada a existência do ficheiro XLS, o programa mostrará uma mensagem de erro e o Job será abortado.
- 9. Faz uma chamada para a Transformação 3 XLS Edit
- 10. Verificação da existência do ficheiro XLS editado.
 - a. Caso não seja encontrada a existência do ficheiro XLS editado, o programa mostrará uma mensagem de erro e o Job será abortado.
- 11. Realiza um ping ao Google para verificar a ligação à internet.
 - a. Caso não haja ligação à internet, o programa mostrará uma mensagem de erro e
 o último ficheiro criado é movido para a raiz do projeto para ser armazenado
 localmente e a pasta que foi criada no ínicio do programa será excluída.

- 12. Envia um email para <u>a24207@alunos.ipca.pt</u> através do endereço de email <u>a24207@sapo.pt</u> com três ficheiros criados anteriormente, o XLS_Generated_Backup (XLS original), o XLS_Generated (XLS com filtro da quantidade de produtos pedidos) e o XLS_Generated_Edit (XLS com a limpeza de campos). Nesse passo foi criado e utilizado um email da <u>Sapo</u>.
 - a. Caso ocorra algum erro ao enviar o email, o programa mostrará uma mensagem de erro e o último ficheiro criado é movido para a raiz do projeto para ser armazenado localmente e a pasta que foi criada no ínicio do programa será excluída.
- 13. A pasta chamada "Generated Data" criada no ínicio do programa é excluída
- 14. O Job é finalizado com sucesso.

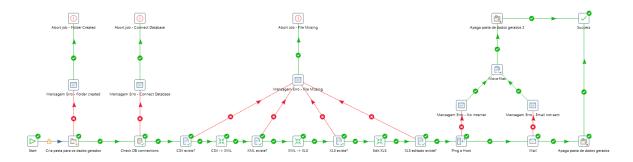


Figura 30 – Visão geral do Job

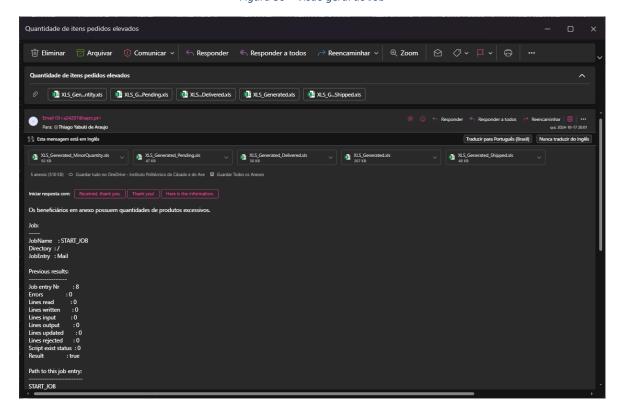


Figura 31 - Captura de tela do Email recebido

6. Vídeo de funcionamento do programa



Figura 32 - QR Code

7. Conclusão

Este trabalho prático permitiu consolidar o conhecimento sobre a utilização de ferramentas de ETL adquirido nas aulas da disciplina de Integração de Sistemas de Informação, em especial a plataforma Pentaho Data Integration, uma plataforma com ampla variedade de funcionalidades para integração e manipulação de dados. Através das atividades desenvolvidas, foi possível gerar dados fictícios, realizar transformações de ficheiros de formatos variados e automatizar processos que facilitam a integração de sistemas de informação. A utilização de técnicas como a conversão de ficheiros CSV para XML e XML para XLS foi eficaz para entender a manipulação e filtragem de dados em diferentes formatos. Além disso, o Job criado demonstra a importância de uma estrutura sequencial para garantir que cada etapa do processo seja completada com sucesso, fornecendo mecanismos de verificação e manipulação dos dados.